《文献检索与论文写作》

课程报告

面向多视图几何重建的学习方法综述：以 VGG 团队为例

组　长：_____

组　员：_____

专　业：_____

班　级：_____

提交日期：_____

摘要

本文围绕多视图几何重建中的学习方法展开综述，聚焦 Oxford Visual Geometry Group（VGG）团队近五年的代表工作，分析该方向如何从传统结构恢复管线逐步演化到端到端学习、可微结构恢复以及统一前馈式几何预测框架。全文首先梳理传统 SfM/MVS 的任务定义与关键瓶颈，再从几何先验注入、对应关系学习、可微优化和统一几何表示四个层面总结 VGG 团队的研究主线，并结合 CoTracker、VGGSfM、VGGT 等代表性成果讨论学习方法对多视图几何重建范式的推动作用。最后，本文从鲁棒性、效率、统一性与可扩展性等角度，对该研究体系的特点、局限与未来趋势进行综合评述。

关键词：多视图几何重建，Structure-from-Motion，视觉几何，对应学习，VGG

ENGLISH DISSERTATION TITLE

LEARNING METHODS FOR MULTI-VIEW GEOMETRIC RECONSTRUCTION: A REVIEW WITH THE VGG TEAM AS A CASE STUDY

ABSTRACT

This report reviews recent learning-based methods for multi-view geometric reconstruction, with a focus on the Oxford Visual Geometry Group (VGG) and its representative works over the last five years. We first revisit the classical SfM/MVS pipeline and its limitations in correspondence estimation, global consistency, and optimization efficiency. We then organize the VGG research line into four connected themes: geometric priors, correspondence learning, differentiable structure from motion, and feed-forward geometric prediction. Representative works such as CoTracker, VGGSfM, and VGGT are discussed to show how learning-based methods have progressively redefined the traditional multi-view geometry pipeline. Finally, we summarize the main characteristics, current limitations, and future opportunities of this research line.

KEY WORDS: multi-view geometry, structure from motion, visual geometry, correspondence learning, VGG

目录

摘要 **1**

ABSTRACT **2**

第一章 引言 **4**
1.1 研究背景与意义 4
1.2 核心关注点与研究难点 4
1.3 选择 VGG 团队作为综述对象的原因 5

第二章 从经典几何到学习化建模的过渡 **6**
2.1 传统多视图几何重建范式 6
2.2 学习方法为何进入多视图几何重建 6
2.3 VGG 团队早期代表工作 6
2.4 本综述的分析视角 7

第三章 几何对应学习与表征增强 **8**
3.1 几何先验如何进入 Transformer 8
3.2 从成对匹配到点轨迹建模 8
3.3 CoTracker3 与真实视频监督 8
3.4 本阶段工作的主线作用 9

第四章 可微几何优化与端到端 SfM **10**
4.1 从模块增强到系统级重构 10
4.2 VGGSfM 的核心思想 10
4.3 与传统 SfM 及同类方法的关系 10

第五章 前馈式统一几何预测与方法趋势 **11**
5.1 从可微优化到统一前馈推断 11
5.2 与相关方法的横向比较 11
5.3 向动态几何与统一表示扩展 11
5.4 本阶段的综合评价 11

第六章 总结与展望 **13**

第一章　引言

多视图几何重建旨在从多张图像中恢复场景的三维结构与相机参数，是三维视觉、机器人感知与数字内容重建中的基础问题。传统方法通常遵循“特征提取与匹配、相机注册、三角化与光束法平差”的经典管线，其中 Bundle Adjustment 被视为保证全局一致性的关键环节[1-2]。然而，这一管线高度依赖手工设计的特征与多阶段优化，面对弱纹理、遮挡、宽基线与大规模图像集合时，往往在鲁棒性、效率与泛化性上面临明显瓶颈[3-4]。

近五年，多视图几何重建逐步出现“学习化”趋势：研究者不再仅将深度网络作为传统流程的局部替代模块，而是尝试让网络直接参与几何对应、相机估计、全局优化乃至统一几何属性预测[5-7]。在这一演进过程中，学习方法的核心价值主要体现在三个方面：其一，利用强表征能力提高跨视角对应的鲁棒性；其二，通过可微模块将传统几何约束纳入端到端训练；其三，进一步以统一前馈模型压缩或替代复杂的后端优化过程[4,7]。

在众多研究团队中，Oxford Visual Geometry Group（VGG）围绕这一主题形成了较为清晰且连续的研究主线。其工作并非对传统几何的简单替代，而是强调将多视图几何的结构性约束、对应关系与优化逻辑逐步转移到学习框架内部。从早期强调几何先验与任务设定的工作[3,8]，到关注点轨迹与跨视角关系建模的 CoTracker 系列[6,9]，再到将结构恢复系统整体可微化的 VGGSfM[4]以及面向统一几何属性预测的 VGGT[7]，VGG 团队的成果较完整地呈现了多视图几何重建“学习化”的方法演进。

基于课程要求，本文选择“多视图几何重建中的学习方法”作为明确研究主题，以 VGG 团队为代表案例展开综述。全文将重点回答以下问题：多视图几何重建的经典问题与瓶颈是什么；学习方法主要改造了传统管线中的哪些环节；VGG 团队的代表性工作之间形成了怎样的递进关系；以及这一研究主线对未来三维视觉方法发展意味着什么。

1.1　研究背景与意义

多视图几何重建广泛应用于自动驾驶、AR/VR、机器人导航、文化遗产数字化与三维内容生成等场景。相较依赖激光雷达或深度相机的主动感知方案，仅依赖普通 RGB 图像的方案具有设备廉价、部署灵活、成像分辨率高等优点，因此长期以来都是计算机视觉的重要研究方向[2,10]。然而，图像到三维的恢复本质上是病态问题，必须借助跨视角几何约束、匹配一致性与全局优化，才能得到可信的相机与结构估计。

1.2　核心关注点与研究难点

该方向当前的核心难点主要包括：跨视角对应的不稳定性、增量式管线的误差累积、复杂场景下的泛化能力不足，以及大规模场景下优化成本过高等[3-4,6]。因此，如

何在保持几何一致性的同时提高学习模型的表达能力与推理效率，构成了近年多视图几何重建研究的关键问题。

1.3　选择 VGG 团队作为综述对象的原因

VGG 团队在该方向的工作具有三个适合作为综述案例的特征。第一，其研究主题高度集中，长期围绕几何先验、跨视角对应、SfM 系统学习化与统一几何表示展开。第二，其代表论文之间存在明显的递进关系，适合从“问题链条”而非“论文堆砌”角度组织综述。第三，其工作发表在 CVPR、ICCV、ECCV 等高水平会议，并普遍提供论文、项目页或代码，便于基于一级来源进行核实与写作[4-5,7]。

第二章　从经典几何到学习化建模的过渡

2.1　传统多视图几何重建范式

传统多视图几何重建通常建立在 Structure-from-Motion（SfM）与 Multi-View Stereo（MVS）框架之上，其核心流程包括局部特征提取、跨图像匹配、几何验证、相机位姿恢复、三角化以及后续的全局优化[1-2]。这一范式的优势在于几何解释清晰、优化目标明确，但同时也高度依赖局部描述子的稳定性与初始化质量。只要前端匹配失败，后续相机估计与重建质量往往会快速恶化。

经典管线的另一个特点是模块化程度高。前端负责提取与关联二维观测，后端则负责全局一致性优化。这种分治结构在工程实现上较为成熟，但也使得整个系统难以直接从最终重建误差中反向修正前端表征[4]。随着深度学习方法在视觉任务中的广泛成功，研究者开始思考：能否让神经网络承担传统管线中最脆弱或最耗时的部分，同时保留多视图几何的结构性约束。

2.2　学习方法为何进入多视图几何重建

学习方法之所以逐步进入多视图几何重建，根本原因在于传统方法在复杂真实场景中的鲁棒性和泛化能力存在明显天花板。面对大视角变化、弱纹理、动态区域与复杂光照时，纯几何启发式往往难以稳定建立高质量对应[3]。而深度网络则能够从大规模数据中学习跨视角不变特征，并利用上下文提高匹配与估计质量。

不过，多视图几何重建的学习化并不意味着完全放弃几何结构。相反，该方向真正有效的工作通常强调“以几何为骨架、以学习为增强”的思路：学习模块负责估计更可靠的特征、轨迹或初始化，而多视图几何仍然提供问题定义、约束形式与评价标准[4-5]。从这一角度看，学习方法在该领域的发展更接近“重新组织几何管线”，而非“黑盒替代几何”。

2.3　VGG 团队早期代表工作

VGG 团队的早期工作体现出鲜明的过渡特征。首先，*Unsupervised Learning of Probably Symmetric Deformable 3D Objects from Images in the Wild* 关注的是在弱监督条件下利用对称性等物理先验恢复三维结构，体现了“先验驱动学习”的思路[8]。该工作虽然更接近单图重建，但它说明了几何与形状先验在学习式三维理解中的基础作用。

其次，*Deep Two-View Structure-from-Motion Revisited* 则更加直接地讨论双视图结构恢复中哪些环节适合学习、哪些环节应保留经典几何求解[3]。该工作并未简单回归相机位姿或深度，而是将光流估计、相对位姿恢复和尺度不变深度估计有机组合，强调经典几何问题的可解性边界。这类工作为后续更系统的可微 SfM 研究奠定了方法论基础。

再次，*Common Objects in 3D*（CO3D）数据集工作则从数据层面补齐了真实世界多视图学习的关键基础设施[10]。由于许多学习方法长期依赖合成数据或小规模真实数据，跨域泛化能力受限，CO3D 提供的大规模真实多视图对象数据集为后续研究提供了更接近真实场景的训练与评测基准。

2.4 本综述的分析视角

基于上述背景，本文后续不按论文年份简单罗列，而是按照学习方法逐步介入传统多视图几何管线的方式来组织。具体而言，本文将从“几何对应学习”“可微结构恢复”“统一前馈预测”三个层面梳理 VGG 团队的代表工作，并在必要处引入 DUSt3R 等相关方法作为横向对照[11]。

第三章　几何对应学习与表征增强

3.1　几何先验如何进入 Transformer

在多视图几何重建中，对应关系始终是最基础的输入信号。VGG 团队在这一问题上的一个关键思路，是将几何规律提前编码到表征学习过程中，而不是仅在后端优化阶段使用几何约束。*A Light Touch Approach to Teaching Transformers Multi-View Geometry* 正是这一思路的代表[5]。该工作并不直接求解完整三维结构，而是研究如何通过极线几何去约束 Transformer 的跨视角注意力分布，使其更容易学习合理的跨图像关系。

这一思路的重要意义在于，它把几何从“解码时的硬约束”转化为“训练时的归纳偏置”。相比直接依赖大规模数据让模型自行发现几何结构，这种做法更符合多视图几何问题本身的物理规律，也为后续将 Transformer 用于更复杂的几何任务提供了方法启发[7]。

3.2　从成对匹配到点轨迹建模

传统 SfM 更擅长处理成对匹配，再通过链接策略拼接成多视图轨迹。但在弱纹理、遮挡、长时序或视角变化较大时，这种做法容易引入链式误差。VGG 团队随后将研究重点推进到点轨迹学习，试图直接从视频或多帧图像中学习更稳定的时空对应表达。

DynamicStereo: Consistent Dynamic Depth From Stereo Videos 关注动态场景中的深度一致性问题，说明了仅靠逐帧估计往往难以获得时间稳定的几何结果，因此需要显式建模时间维度上的几何关系[12]。这一工作虽然面向动态深度估计，但其核心价值在于强调“对应关系并非静态成对关系，而是时空一致性问题”。

在这一基础上，*CoTracker: It is Better to Track Together* 进一步提出联合点追踪思想[6]。与将每个点独立处理的追踪器不同，CoTracker 通过共享上下文、联合建模大量点轨迹，使模型能够更好地处理遮挡、出画与长时段追踪。对于多视图几何重建而言，这种轨迹形式具有重要意义，因为它提供了比传统稀疏匹配更稳定、更密集、更适合后续几何求解的观测基础。

3.3　CoTracker3 与真实视频监督

CoTracker3: Simpler and Better Point Tracking by Pseudo-Labelling Real Videos 延续了轨迹建模思路，但重点转向如何更有效地利用真实视频数据[9]。该工作通过伪标签机制减少人工标注依赖，强化了模型在真实场景中的可迁移性与训练效率。对本文主题而言，其价值不只体现在追踪性能提升上，更在于说明高质量对应学习正在从“算法模块”变成“多视图几何系统的通用基础设施”。

3.4 本阶段工作的主线作用

从 Light Touch 到 CoTracker 系列，VGG 团队并未急于直接构建统一的三维重建模型，而是优先解决几何系统中最基础、最脆弱的输入问题：如何获得稳定可信的跨视角关系。这一阶段的研究成果为后续 VGGSfM 的全局相机恢复和可微优化提供了更强的底层观测，也解释了为何 VGG 团队的方法主线具有明显的递进性，而非彼此割裂的独立尝试。

第四章　可微几何优化与端到端 SfM

4.1　从模块增强到系统级重构

如果说对应学习解决的是前端观测质量问题，那么可微 SfM 则进一步触及传统多视图几何的核心系统结构。过去许多深度学习方法只替换匹配、深度或位姿初始化等局部模块，而后端仍沿用不可微的经典优化器。这使得系统难以真正实现端到端学习，也限制了最终误差对前端表征的反馈能力[3]。

VGGSfM: Visual Geometry Grounded Deep Structure From Motion 在这方面迈出关键一步[4]。该工作将深度点轨迹、相机恢复、三角化和 Bundle Adjustment 组织到同一可微框架中，使传统 SfM 系统中的多个关键环节能够在统一目标下训练。与仅对某个部件做学习增强的方案相比，VGGSfM 更接近对整个结构恢复问题的“系统级重构”。

4.2　VGGSfM 的核心思想

VGGSfM 的一个重要特点是同时强调“几何 grounded”与“深度学习驱动”。其输入不再是传统关键点匹配链，而是由点轨迹提供的更稳定观测；其相机恢复不是增量式逐步注册，而是尝试同步估计全部相机；其三维点优化则通过可微的 BA 层来完成[4]。这意味着模型不仅在前端表征上使用学习方法，也在后端优化层面尽量保留传统几何问题的可解释形式。

从研究主线角度看，VGGSfM 是 VGG 团队从“增强几何管线”走向“重构几何管线”的转折点。一方面，它延续了前一阶段对轨迹、匹配和几何约束的重视；另一方面，它通过可微化方式将原本分离的多个模块组织到统一训练框架中，为进一步走向前馈式统一几何预测创造了条件。

4.3　与传统 SfM 及同类方法的关系

相较于 COLMAP 等传统系统，VGGSfM 的优势主要在于能够借助学习表征改善鲁棒性，并通过统一训练强化全局一致性[2,4]。相较于只在前端使用深度特征、后端仍完全依赖传统不可微求解器的混合方案，VGGSfM 则体现出更强的系统整合能力。

不过，VGGSfM 仍然保留了优化层，说明这一阶段的重点仍是“让几何优化可学习”，而非完全放弃优化。这一点在研究路径上十分关键：它既保留了传统几何的确定性和解释性，也暴露出后续研究进一步追求效率与统一性的方向，即能否在不依赖复杂测试时优化的前提下，直接输出关键三维属性。

第五章　前馈式统一几何预测与方法趋势

5.1　从可微优化到统一前馈推断

在可微 SfM 之后，VGG 团队研究主线继续向“统一化”与“前馈化”推进。*VGGT: Visual Geometry Grounded Transformer* 提出以单个前馈网络直接预测相机参数、深度图、点图和三维点轨迹等关键几何属性，试图将传统多阶段系统进一步压缩为统一模型[7]。这表明研究问题的表述已经从“如何提升某一几何模块”转向“如何以统一表示组织多个几何任务”。

VGGT 的意义不只在于预测速度更快，更在于它反映出多视图几何重建研究的一个重要趋势：学习模型开始承担传统后端优化原本负责的更大一部分工作。相比于需要测试时迭代求解的系统，前馈式方法在部署、复用和跨任务迁移上具有更高潜力[7]。这也是 VGGT 被视为 VGG 团队研究主线阶段性代表作的重要原因。

5.2　与相关方法的横向比较

为了更好理解 VGGT 的定位，可以将其与 DUSt3R 等近期方法进行对照。DUSt3R 也强调从图像中直接恢复三维几何，并在一定程度上简化传统结构恢复流程[11]。但与 VGG 团队这一主线相比，VGGT 更强调统一的几何属性输出，以及与前述几何先验、轨迹学习和可微 SfM 研究的连续性。

此外，*Splatter Image: Ultra-Fast Single-View 3D Reconstruction* 虽然聚焦单图重建，但它同样体现出 VGG 团队对“前馈式三维表示”的持续探索[13]。这说明 VGG 团队并非只在传统多视图任务上推进学习化，也在尝试寻找更统一、更高效的三维表示方式。

5.3　向动态几何与统一表示扩展

这一趋势还继续延伸到动态几何场景。*Dynamic Point Maps: A Versatile Representation for Dynamic 3D Reconstruction* 说明，当场景随时间变化时，统一点图表示仍可作为多任务几何建模的重要中间层[14]。尽管这类工作已部分超出本文“多视图几何重建”的核心范围，但它们揭示了一个清晰方向：未来的学习方法可能不再局限于重建某个静态结果，而是形成可支持深度、相机、点云、轨迹乃至动态场景理解的统一几何表征。

5.4　本阶段的综合评价

从 VGG 团队近五年的方法演进来看，前馈式统一几何预测并不是凭空出现的，而是建立在前述几何先验注入、点轨迹学习与可微 SfM 逐步成熟的基础之上。也正

因为如此，VGGT 等方法更适合被理解为一条研究主线的阶段性总结，而不是孤立的单篇突破。对本文主题而言，本阶段最值得强调的不是单个模型的性能，而是“多视图几何重建正在从优化驱动转向表示驱动与模型驱动”的方法论变化。

第六章　总结与展望

本文围绕“多视图几何重建中的学习方法”这一主题，以 VGG 团队为例梳理了近五年的代表性研究主线。整体来看，该团队的工作并非简单追求端到端替代，而是沿着一条较为清晰的路径逐步推进：先利用几何先验改善跨视角表征，再通过点轨迹学习提升对应质量，随后将结构恢复系统整体可微化，最后进一步走向统一前馈式几何预测[4-7]。

从研究贡献上看，VGG 团队的工作至少体现出三点特色。第一，坚持以多视图几何问题本身为核心，而非将三维重建视作纯粹的黑盒回归任务。第二，强调系统级整合，将对应、优化与表示逐步组织到统一框架中。第三，关注统一几何表示的潜力，使学习方法能够服务于多个相关任务，而不仅限于单一指标提升。

当然，该研究主线也仍面临若干问题。其一，尽管统一前馈模型提高了效率，但对训练数据规模、模型容量和任务设定的依赖也更强。其二，复杂场景中的动态因素、遮挡与泛化问题仍然没有被彻底解决。其三，如何在保持几何可解释性的同时进一步提升模型统一性与迁移能力，仍是未来的重要研究方向。

结合当前发展趋势，后续研究可能继续沿三个方向推进：一是进一步探索更统一的几何中间表示，用同一模型支持相机恢复、深度估计、点云生成与轨迹推断；二是扩展到动态 4D 场景，使学习化多视图几何从静态场景走向时空一致建模；三是与机器人感知、具身智能和三维内容生成等下游任务形成更紧密结合。对课程综述写作而言，VGG 团队的研究体系提供了一个较理想的分析样本，因为它既能代表该方向的重要技术趋势，也便于清晰展示论文之间的递进关系与方法脉络。

参考文献

[1] TRIGGS B, MCLAUCHLAN P F, HARTLEY R I, et al. Bundle Adjustment – A Modern Synthesis[J]. Lecture Notes in Computer Science, 2000, 1883: 298-372.

[2] SCHÖNBERGER J L, FRAHM J M. Structure-from-Motion Revisited[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 4104-4113.

[3] WANG J, ZHONG Y, DAI Y, et al. Deep Two-View Structure-From-Motion Revisited[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 8953-8962. https://openaccess.thecvf.com/content/CVPR2021/html/Wang_Deep_Two-View_Structure-From-Motion_Revisited_CVPR_2021_paper.html.

[4] WANG J, KARAEV N, RUPPRECHT C, et al. VGGSfM: Visual Geometry Grounded Deep Structure From Motion[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 21686-21697. https://openaccess.thecvf.com/content/CVPR2024/html/Wang_VGGSfM_Visual_Geometry_Grounded_Deep_Structure_From_Motion_CVPR_2024_paper.html.

[5] BHALGAT Y, HENRIQUES J F, ZISSERMAN A. A Light Touch Approach to Teaching Transformers Multi-View Geometry[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 4958-4969. https://openaccess.thecvf.com/content/CVPR2023/html/Bhalgat_A_Light_Touch_Approach_to_Teaching_Transformers_Multi-View_Geometry_CVPR_2023_paper.html.

[6] KARAEV N, ROCCO I, GRAHAM B, et al. CoTracker: It is Better to Track Together[C/OL]//European Conference on Computer Vision (ECCV). 2024. https://arxiv.org/abs/2307.07635.

[7] WANG J, CHEN M, KARAEV N, et al. VGGT: Visual Geometry Grounded Transformer[J/OL]. arXiv preprint arXiv:2503.11651, 2025. https://arxiv.org/abs/2503.11651.

[8] WU S, RUPPRECHT C, VEDALDI A. Unsupervised Learning of Probably Symmetric Deformable 3D Objects from Images in the Wild[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020. https://arxiv.org/abs/1911.11130.

[9] KARAEV N, MAKAROV Y, WANG J, et al. CoTracker3: Simpler and Better Point Tracking by Pseudo-Labelling Real Videos[C/OL]//Proceedings of the

IEEE/CVF International Conference on Computer Vision (ICCV). 2025: 6013-6022. https://openaccess.thecvf.com/content/ICCV2025/html/Karaev_CoTracker3_Simpler_and_Better_Point_Tracking_by_Pseudo-Labelling_Real_Videos_ICCV_2025_paper.html.

[10] REIZENSTEIN J, SHAPOVALOV R, HENZLER P, et al. Common Objects in 3D: Large-Scale Learning and Evaluation of Real-Life 3D Category Reconstruction[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 10901-10911. https://openaccess.thecvf.com/content/ICCV2021/html/Reizenstein_Common_Objects_in_3D_Large-Scale_Learning_and_Evaluation_of_Real-Life_ICCV_2021_paper.html.

[11] WANG S, LEROY V, CABON Y, et al. DUSt3R: Geometric 3D Vision Made Easy[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 20697-20709. https://openaccess.thecvf.com/content/CVPR2024/html/Wang_DUSt3R_Geometric_3D_Vision_Made_Easy_CVPR_2024_paper.html.

[12] KARAEV N, ROCCO I, GRAHAM B, et al. DynamicStereo: Consistent Dynamic Depth From Stereo Videos[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 13229-13239. https://openaccess.thecvf.com/content/CVPR2023/html/Karaev_DynamicStereo_Consistent_Dynamic_Depth_From_Stereo_Videos_CVPR_2023_paper.html.

[13] SZYMANOWICZ S, RUPPRECHT C, VEDALDI A. Splatter Image: Ultra-Fast Single-View 3D Reconstruction[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 10208-10217. https://openaccess.thecvf.com/content/CVPR2024/html/Szymanowicz_Splatter_Image_Ultra-Fast_Single-View_3D_Reconstruction_CVPR_2024_paper.html.

[14] SUCAR E, LAI Z, INSAFUTDINOV E, et al. Dynamic Point Maps: A Versatile Representation for Dynamic 3D Reconstruction[J/OL]. arXiv preprint arXiv:2503.16318, 2025. https://arxiv.org/abs/2503.16318.