浙江工業大學

《文献检索与论文写作》

课程报告

面向多视图几何重建的学习方法综述：以 VGG 团队为例

组　长：_____

组　员：_____

专　业：_____

班　级：_____

提交日期：_____

摘要

本文围绕多视图几何重建中的学习方法展开综述，聚焦 Oxford Visual Geometry Group（VGG）团队近五年的代表工作，分析该方向如何从传统结构恢复管线逐步演化到端到端学习、可微结构恢复以及统一前馈式几何预测框架。全文首先梳理传统 SfM/MVS 的任务定义与关键瓶颈，再从几何先验注入、对应关系学习、可微优化和统一几何表示四个层面总结 VGG 团队的研究主线，并结合 CoTracker、VGGSfM、VGGT 等代表性成果讨论学习方法对多视图几何重建范式的推动作用。最后，本文从鲁棒性、效率、统一性与可扩展性等角度，对该研究体系的特点、局限与未来趋势进行综合评述。

关键词：多视图几何重建，Structure-from-Motion，视觉几何，对应学习，VGG

ENGLISH DISSERTATION TITLE

LEARNING METHODS FOR MULTI-VIEW GEOMETRIC RECONSTRUCTION: A REVIEW WITH THE VGG TEAM AS A CASE STUDY

ABSTRACT

This report reviews recent learning-based methods for multi-view geometric reconstruction, with a focus on the Oxford Visual Geometry Group (VGG) and its representative works over the last five years. We first revisit the classical SfM/MVS pipeline and its limitations in correspondence estimation, global consistency, and optimization efficiency. We then organize the VGG research line into four connected themes: geometric priors, correspondence learning, differentiable structure from motion, and feed-forward geometric prediction. Representative works such as CoTracker, VGGSfM, and VGGT are discussed to show how learning-based methods have progressively redefined the traditional multi-view geometry pipeline. Finally, we summarize the main characteristics, current limitations, and future opportunities of this research line.

KEY WORDS: multi-view geometry, structure from motion, visual geometry, correspondence learning, VGG

目录

摘要 **1**

ABSTRACT **2**

第一章 引言 **4**
1.1 研究背景与意义 4
1.2 核心关注点与研究难点 5
1.3 选择 VGG 团队作为综述对象的原因 5

第二章 从经典几何到学习化建模的过渡 **6**
2.1 传统多视图几何重建范式 6
2.2 学习方法为何进入多视图几何重建 6
2.3 与其他三维路线的关系 6
2.4 VGG 团队早期代表工作 7
2.5 本综述的分析视角 8

第三章 几何对应学习与表征增强 **9**
3.1 几何先验如何进入 Transformer 9
3.2 从成对匹配到点轨迹建模 9
3.3 CoTracker3 与真实视频监督 10
3.4 从对应学习到统一几何表征的过渡 10
3.5 本阶段工作的主线作用 10

第四章 可微几何优化与端到端 SfM **12**
4.1 从模块增强到系统级重构 12
4.2 VGGSfM 的核心思想 12
4.3 VGGSfM 在研究脉络中的关键作用 12
4.4 与传统 SfM 及同类方法的关系 13
4.5 本阶段的小结 13

第五章 前馈式统一几何预测与方法趋势 **14**
5.1 从可微优化到统一前馈推断 14
5.2 VGGT 的统一输出思想 14
5.3 与相关方法的横向比较 14
5.4 向动态几何与统一表示扩展 15
5.5 本阶段的综合评价 16

第六章 总结与展望 **17**

第一章　引言

多视图几何重建旨在从多张图像中恢复场景的三维结构与相机参数，是三维视觉、机器人感知与数字内容重建中的基础问题。传统方法通常遵循“特征提取与匹配、相机注册、三角化与光束法平差”的经典管线，其中 Bundle Adjustment 被视为保证全局一致性的关键环节[1-2]。然而，这一管线高度依赖手工设计的特征与多阶段优化，面对弱纹理、遮挡、宽基线与大规模图像集合时，往往在鲁棒性、效率与泛化性上面临明显瓶颈[3-4]。

近五年，多视图几何重建逐步出现“学习化”趋势：研究者不再仅将深度网络作为传统流程的局部替代模块，而是尝试让网络直接参与几何对应、相机估计、全局优化乃至统一几何属性预测[5-7]。在这一演进过程中，学习方法的核心价值主要体现在三个方面：其一，利用强表征能力提高跨视角对应的鲁棒性；其二，通过可微模块将传统几何约束纳入端到端训练；其三，进一步以统一前馈模型压缩或替代复杂的后端优化过程[4,7]。

在众多研究团队中，Oxford Visual Geometry Group（VGG）围绕这一主题形成了较为清晰且连续的研究主线。其工作并非对传统几何的简单替代，而是强调将多视图几何的结构性约束、对应关系与优化逻辑逐步转移到学习框架内部。从早期强调几何先验与任务设定的工作[3,8]，到关注点轨迹与跨视角关系建模的 CoTracker 系列[6,9]，再到将结构恢复系统整体可微化的 VGGSfM[4]以及面向统一几何属性预测的 VGGT[7]，VGG 团队的成果较完整地呈现了多视图几何重建“学习化”的方法演进。

基于课程要求，本文选择“多视图几何重建中的学习方法”作为明确研究主题，以 VGG 团队为代表案例展开综述。全文将重点回答以下问题：多视图几何重建的经典问题与瓶颈是什么；学习方法主要改造了传统管线中的哪些环节；VGG 团队的代表性工作之间形成了怎样的递进关系；以及这一研究主线对未来三维视觉方法发展意味着什么。

1.1　研究背景与意义

多视图几何重建广泛应用于自动驾驶、AR/VR、机器人导航、文化遗产数字化与三维内容生成等场景。相较依赖激光雷达或深度相机的主动感知方案，仅依赖普通 RGB 图像的方案具有设备廉价、部署灵活、成像分辨率高等优点，因此长期以来都是计算机视觉的重要研究方向[2,10]。然而，图像到三维的恢复本质上是病态问题，必须借助跨视角几何约束、匹配一致性与全局优化，才能得到可信的相机与结构估计。

从应用层面看，多视图几何重建并不只是一个传统视觉任务，而是连接二维感知与三维世界理解的基础桥梁。在自动驾驶与机器人系统中，场景几何决定了障碍物定位、路径规划和交互安全；在 AR/VR 中，几何重建又直接关系到虚实对齐、遮挡关系与真实感渲染；在数字文化遗产保护与工业检测场景中，稳定而高精度的三维恢复则决定了后续建模、存档与测量分析的质量。因此，如何让仅依赖图像的三维重建方法变得更稳健、更高效、更易泛化，具有明确的工程价值与学术价值。

同时，该方向之所以长期具有研究吸引力，还在于它天然处于“物理规律”与“数据驱动学习”之间的交汇点。一方面，多视图几何由投影模型、相对运动和重投影误差等明确数学结构决定；另一方面，真实世界中的纹理缺失、反射、遮挡与动态变化，又使得纯解析方法难以覆盖全部复杂情形。也正是在这一张力下，学习方法才逐渐成为推动该方向继续发展的关键力量。

1.2　核心关注点与研究难点

该方向当前的核心难点主要包括：跨视角对应的不稳定性、增量式管线的误差累积、复杂场景下的泛化能力不足，以及大规模场景下优化成本过高等[3-4,6]。因此，如何在保持几何一致性的同时提高学习模型的表达能力与推理效率，构成了近年多视图几何重建研究的关键问题。

进一步细分，这些难点实际上对应多视图几何管线中的三个关键环节。第一是观测层，即如何从图像中获得高质量、可长期保持一致的对应关系；第二是求解层，即如何在相机恢复、三角化与全局优化阶段维持数值稳定与几何可解释性；第三是表示层，即如何让模型输出的几何结果既便于重建本身，也能够服务于深度估计、跟踪、视图合成和动态场景理解等下游任务。VGG 团队近五年的工作，恰恰可以被理解为分别围绕这三个环节逐步展开。

此外，近两年该方向又新增了一类重要问题，即统一性问题。过去多视图几何系统更倾向于“一个模块做一件事”，而当前越来越多方法开始尝试让同一模型同时处理相机参数、深度、点图和轨迹等多种属性[7,11-12]。这意味着研究目标已经从“单模块精度提升”逐步转向“统一场景几何表示的构建”，这也是本文在综述中将 VGGSfM 和 VGGT 视为关键节点的重要原因。

1.3　选择 VGG 团队作为综述对象的原因

VGG 团队在该方向的工作具有三个适合作为综述案例的特征。第一，其研究主题高度集中，长期围绕几何先验、跨视角对应、SfM 系统学习化与统一几何表示展开。第二，其代表论文之间存在明显的递进关系，适合从“问题链条”而非“论文堆砌”角度组织综述。第三，其工作发表在 CVPR、ICCV、ECCV 等高水平会议，并普遍提供论文、项目页或代码，便于基于一级来源进行核实与写作[4-5,7]。

更重要的是，VGG 团队的方法路径具有较强的代表性和可分析性。与某些仅在单一任务或单一模型上取得突破的研究不同，VGG 团队的工作覆盖了数据、表征、几何求解与统一预测等多个层面，因而能够较完整地反映当前多视图几何重建学习化的总体趋势。与此同时，这条研究主线又保持了足够清晰的边界，使本文可以围绕“多视图几何重建中的学习方法”这一明确主题展开，而不会滑向泛泛的“某团队视觉研究综述”。

第二章　从经典几何到学习化建模的过渡

2.1　传统多视图几何重建范式

传统多视图几何重建通常建立在 Structure-from-Motion（SfM）与 Multi-View Stereo（MVS）框架之上，其核心流程包括局部特征提取、跨图像匹配、几何验证、相机位姿恢复、三角化以及后续的全局优化[1-2]。这一范式的优势在于几何解释清晰、优化目标明确，但同时也高度依赖局部描述子的稳定性与初始化质量。只要前端匹配失败，后续相机估计与重建质量往往会快速恶化。

经典管线的另一个特点是模块化程度高。前端负责提取与关联二维观测，后端则负责全局一致性优化。这种分治结构在工程实现上较为成熟，但也使得整个系统难以直接从最终重建误差中反向修正前端表征[4]。随着深度学习方法在视觉任务中的广泛成功，研究者开始思考：能否让神经网络承担传统管线中最脆弱或最耗时的部分，同时保留多视图几何的结构性约束。

2.2　学习方法为何进入多视图几何重建

学习方法之所以逐步进入多视图几何重建，根本原因在于传统方法在复杂真实场景中的鲁棒性和泛化能力存在明显天花板。面对大视角变化、弱纹理、动态区域与复杂光照时，纯几何启发式往往难以稳定建立高质量对应[3]。而深度网络则能够从大规模数据中学习跨视角不变特征，并利用上下文提高匹配与估计质量。

不过，多视图几何重建的学习化并不意味着完全放弃几何结构。相反，该方向真正有效的工作通常强调“以几何为骨架、以学习为增强”的思路：学习模块负责估计更可靠的特征、轨迹或初始化，而多视图几何仍然提供问题定义、约束形式与评价标准[4-5]。从这一角度看，学习方法在该领域的发展更接近“重新组织几何管线”，而非“黑盒替代几何”。

2.3　与其他三维路线的关系

为了更准确界定本文主题，有必要把“多视图几何重建中的学习方法”与近年来几条相邻研究路线区分开来。第一类相邻路线是以 NeRF 为代表的神经隐式表示方法[13]。这类方法强调通过连续场函数和体渲染实现高质量新视角合成，在稠密视图条件下具有极强表现，但其核心目标更偏向外观重建与可微渲染，而不一定以显式相机恢复和通用几何输出为中心。

第二类相邻路线是以 3D Gaussian Splatting 为代表的高效显式渲染表示[14]。相比 NeRF，这类方法在训练和渲染效率上更有优势，也推动了“前馈式三维表示”研究的快速发展。但从问题设定上看，它们多数仍更偏向场景表示与新视角合成，而不是经典多视图几何意义上的结构恢复系统。

第三类相邻路线是近两年兴起的统一几何预测方法，以 DUSt3R 和 MASt3R 为

代表[11-12]。这一方向与本文主题关系最为接近，因为它们同样试图弱化传统 SfM 的复杂流程，以统一模型直接恢复几何结构或密集匹配。也正因如此，VGG 团队后续的 VGGT 更值得放在这一背景下理解：它并不是孤立地宣称“前馈更好”，而是在一类统一几何预测方法共同兴起的背景下，沿着 VGG 自身的主线进一步推进。

除此之外，VGG 团队本身也在单图三维重建和生成先验方向上有所探索，例如 RealFusion、PC^2 与 Splatter Image 等工作[15-17]。这些方法与本文主线并不完全重合，因为它们更强调单视图条件下的三维表示生成、点云扩散或快速渲染表达，而非多视图几何系统本身；但它们仍然具有分析价值，因为它们说明 VGG 团队在更广泛的三维视觉研究中持续关注一个共同问题，即如何把几何结构压缩到可学习、可复用的中间表示中。正因如此，本文会把这些工作放在“边界与延伸”位置，而不将其作为主线展开。

2.4　VGG 团队早期代表工作

VGG 团队的早期工作体现出鲜明的过渡特征。首先，*Unsupervised Learning of Probably Symmetric Deformable 3D Objects from Images in the Wild* 关注的是在弱监督条件下利用对称性等物理先验恢复三维结构，体现了“先验驱动学习”的思路[8]。该工作虽然更接近单图重建，但它说明了几何与形状先验在学习式三维理解中的基础作用。

其次，*Deep Two-View Structure-from-Motion Revisited* 则更加直接地讨论双视图结构恢复中哪些环节适合学习、哪些环节应保留经典几何求解[3]。该工作并未简单回归相机位姿或深度，而是将光流估计、相对位姿恢复和尺度不变深度估计有机组合，强调经典几何问题的可解性边界。这类工作为后续更系统的可微 SfM 研究奠定了方法论基础。

再次，*Common Objects in 3D*（CO3D）数据集工作则从数据层面补齐了真实世界多视图学习的关键基础设施[10]。由于许多学习方法长期依赖合成数据或小规模真实数据，跨域泛化能力受限，CO3D 提供的大规模真实多视图对象数据集为后续研究提供了更接近真实场景的训练与评测基准。

如果把这些工作放在统一视角下观察，可以发现 VGG 团队的早期过渡期其实围绕三个基本判断展开。第一，纯粹依赖黑盒回归难以充分利用多视图几何中的可解结构。第二，若没有足够真实的数据支撑，再强的模型也很难在真实场景中稳定泛化。第三，几何先验并不是束缚学习的限制条件，反而可以作为提升学习效率和推理可靠性的关键归纳偏置。正是基于这三点判断，后续关于 Transformer 注意力、点轨迹和可微 SfM 的工作才具备清晰的方法论延续性。

从课程综述写作角度看，这一阶段还有一个容易被忽略、但非常关键的意义：它为后文建立了“为什么 VGG 主线值得单独分析”的逻辑基础。许多团队也在做三维重建或视觉几何，但并不是所有研究都同时覆盖问题设定、训练数据、观测形式与系统求解四个层面。VGG 团队早期工作的价值，恰恰在于它们已经同时触及这四个层

面，从而使后续工作能够沿着一条连贯主线展开，而不是在不同任务之间跳跃。

2.5 本综述的分析视角

基于上述背景，本文后续不按论文年份简单罗列，而是按照学习方法逐步介入传统多视图几何管线的方式来组织。具体而言，本文将从“几何对应学习”“可微结构恢复”“统一前馈预测”三个层面梳理 VGG 团队的代表工作，并在必要处引入 DUSt3R 等相关方法作为横向对照[11]。

这一分析视角的优点在于，它能更好回答课程综述中最重要的问题：该研究方向主要关注什么问题、采用了哪些方法、研究思路是如何逐步推进的。换言之，本文不会把 VGG 团队的论文写成平行罗列，而会强调它们之间在问题设置、方法设计和研究目标上的前后联系，尤其关注每一步工作是如何针对上一阶段的不足提出修正或扩展的。

第三章　几何对应学习与表征增强

3.1　几何先验如何进入 Transformer

在多视图几何重建中，对应关系始终是最基础的输入信号。VGG 团队在这一问题上的一个关键思路，是将几何规律提前编码到表征学习过程中，而不是仅在后端优化阶段使用几何约束。*A Light Touch Approach to Teaching Transformers Multi-View Geometry* 正是这一思路的代表[5]。该工作并不直接求解完整三维结构，而是研究如何通过极线几何去约束 Transformer 的跨视角注意力分布，使其更容易学习合理的跨图像关系。

这一思路的重要意义在于，它把几何从“解码时的硬约束”转化为“训练时的归纳偏置”。相比直接依赖大规模数据让模型自行发现几何结构，这种做法更符合多视图几何问题本身的物理规律，也为后续将 Transformer 用于更复杂的几何任务提供了方法启发[7]。

从方法史角度看，这一工作之所以重要，是因为它回应了视觉 Transformer 在几何任务中最核心的质疑之一：如果注意力机制天然更擅长语义关系建模，那么它能否同样遵守极线几何、相对视角与投影结构这些严格的空间约束。Light Touch 给出的答案是肯定的，但前提是需要通过合适的训练方式显式引导模型。也就是说，Transformer 并不自动具备几何意识，几何先验仍然需要以恰当形式进入学习过程。

3.2　从成对匹配到点轨迹建模

传统 SfM 更擅长处理成对匹配，再通过链接策略拼接成多视图轨迹。但在弱纹理、遮挡、长时序或视角变化较大时，这种做法容易引入链式误差。VGG 团队随后将研究重点推进到点轨迹学习，试图直接从视频或多帧图像中学习更稳定的时空对应表达。

DynamicStereo: Consistent Dynamic Depth From Stereo Videos 关注动态场景中的深度一致性问题，说明了仅靠逐帧估计往往难以获得时间稳定的几何结果，因此需要显式建模时间维度上的几何关系[18]。这一工作虽然面向动态深度估计，但其核心价值在于强调“对应关系并非静态成对关系，而是时空一致性问题”。

在这一基础上，*CoTracker: It is Better to Track Together* 进一步提出联合点追踪思想[6]。与将每个点独立处理的追踪器不同，CoTracker 通过共享上下文、联合建模大量点轨迹，使模型能够更好地处理遮挡、出画与长时段追踪。对于多视图几何重建而言，这种轨迹形式具有重要意义，因为它提供了比传统稀疏匹配更稳定、更密集、更适合后续几何求解的观测基础。

这一变化实质上改变了多视图几何中“观测”的定义。经典 SfM 中的观测往往表现为若干离散关键点在不同图像中的局部对应，而 CoTracker 这类方法则把观测提升为具有时空连续性的轨迹片段。轨迹不仅编码了点在多帧中的位置变化，还隐含携带了可见性、局部运动一致性与上下文约束等信息。对于后续相机恢复和全局优化而

言，这种观测显然比脆弱的成对匹配更适合支撑复杂场景下的学习化几何系统。

3.3　CoTracker3 与真实视频监督

CoTracker3: Simpler and Better Point Tracking by Pseudo-Labelling Real Videos 延续了轨迹建模思路，但重点转向如何更有效地利用真实视频数据[9]。该工作通过伪标签机制减少人工标注依赖，强化了模型在真实场景中的可迁移性与训练效率。对本文主题而言，其价值不只体现在追踪性能提升上，更在于说明高质量对应学习正在从“算法模块”变成“多视图几何系统的通用基础设施”。

这一点尤其值得在综述中强调，因为它揭示了学习方法进入多视图几何后的一个常见规律：真正有长期影响力的模块，往往不是针对某个狭窄 benchmark 调整出来的专用技巧，而是能够反复服务于多个后续任务的中间表示。CoTracker3 的意义就在于，它使点轨迹从“视觉跟踪问题的输出”转化成了“多视图几何、动态场景理解与统一几何建模的共享输入”。

与此相呼应，*SHIC: Shape-Image Correspondences with no Keypoint Supervision* 虽然不直接面向多视图 SfM，但也体现了 VGG 团队在“对应关系学习”上的另一条相关支线[19]。该工作试图在缺乏关键点人工标注的情况下学习图像到模板形状的对应关系，说明几何对应的监督来源正在发生变化：过去依赖人工关键点或显式几何标注，而现在更多借助基础模型、模板渲染与弱监督信号构造可迁移的监督。这一变化与 CoTracker3 使用真实视频伪标签强化轨迹学习的思路在方法论上是一致的，即高质量对应不一定必须来自昂贵标注，也可以由更大规模、更弱形式但更可迁移的监督产生。

3.4　从对应学习到统一几何表征的过渡

如果说 Light Touch 解决的是“如何让表征更具几何意识”，CoTracker 系列解决的则是“如何让观测本身更稳定、更连续”。这两者结合起来，为后续研究提供了一个自然过渡：当跨视角注意力已经能够学习几何规律、而点轨迹又能够提供更高质量的观测时，系统接下来就不再局限于局部匹配优化，而可以尝试直接重构整个结构恢复管线。这也正是 VGGSfM 得以成立的前提。

因此，本阶段工作在整条研究主线中的真正价值，不只是改善对应精度，更是为“系统级几何学习化”准备输入基础和方法前提。没有这一阶段对几何先验、轨迹建模和弱监督对应学习的打磨，后续可微 SfM 与统一前馈预测很难稳定成立。

3.5　本阶段工作的主线作用

从 Light Touch 到 CoTracker 系列，VGG 团队并未急于直接构建统一的三维重建模型，而是优先解决几何系统中最基础、最脆弱的输入问题：如何获得稳定可信的

跨视角关系。这一阶段的研究成果为后续 VGGSfM 的全局相机恢复和可微优化提供了更强的底层观测，也解释了为何 VGG 团队的方法主线具有明显的递进性，而非彼此割裂的独立尝试。

总结来看，几何对应学习阶段的研究贡献主要体现在三个方面。第一，把几何先验从后处理约束前移到表征学习本身。第二，把离散匹配提升为连续轨迹，从而提高观测质量。第三，把对应学习的结果做成可迁移的通用模块，而不是一次性服务于某个单独任务。正因为具备这三点特征，这一阶段才成为 VGG 团队后续系统级方法的重要支点。

如果从更宽的领域视角来评价，这一阶段也是多视图几何重建开始接近“基础表示”思维的时刻。过去研究更关心某个具体任务上的局部精度提升，而 Light Touch、CoTracker3 乃至 SHIC 这类工作则开始追问：是否能够先学到一种足够稳健的几何关系表示，再将其迁移到相机恢复、深度估计、形状对应和动态理解等不同任务中。对课程综述而言，这一点非常重要，因为它能够帮助读者理解后续 VGGSfM 与 VGGT 为什么不只是更大的模型，而是建立在新的表示观之上。

第四章　可微几何优化与端到端 SfM

4.1　从模块增强到系统级重构

如果说对应学习解决的是前端观测质量问题，那么可微 SfM 则进一步触及传统多视图几何的核心系统结构。过去许多深度学习方法只替换匹配、深度或位姿初始化等局部模块，而后端仍沿用不可微的经典优化器。这使得系统难以真正实现端到端学习，也限制了最终误差对前端表征的反馈能力[3]。

VGGSfM: Visual Geometry Grounded Deep Structure From Motion 在这方面迈出关键一步[4]。该工作将深度点轨迹、相机恢复、三角化和 Bundle Adjustment 组织到同一可微框架中，使传统 SfM 系统中的多个关键环节能够在统一目标下训练。与仅对某个部件做学习增强的方案相比，VGGSfM 更接近对整个结构恢复问题的“系统级重构”。

4.2　VGGSfM 的核心思想

VGGSfM 的一个重要特点是同时强调“几何 grounded”与“深度学习驱动”。其输入不再是传统关键点匹配链，而是由点轨迹提供的更稳定观测；其相机恢复不是增量式逐步注册，而是尝试同步估计全部相机；其三维点优化则通过可微的 BA 层来完成[4]。这意味着模型不仅在前端表征上使用学习方法，也在后端优化层面尽量保留传统几何问题的可解释形式。

从研究主线角度看，VGGSfM 是 VGG 团队从“增强几何管线”走向“重构几何管线”的转折点。一方面，它延续了前一阶段对轨迹、匹配和几何约束的重视；另一方面，它通过可微化方式将原本分离的多个模块组织到统一训练框架中，为进一步走向前馈式统一几何预测创造了条件。

更具体地看，VGGSfM 的方法贡献可以概括为三个层次。第一，它改变了传统 SfM 依赖稀疏关键点链条的观测形式，以更加密集且时间一致的点轨迹作为输入。第二，它改变了传统系统的求解方式，不再只依赖局部增量式注册，而是更强调全局相机恢复与统一优化。第三，它改变了训练信号的流动方式，使最终重投影误差能够反向影响前端特征与轨迹估计，从而形成完整闭环[4,6]。这三点共同表明，VGGSfM 并不是把经典算法照搬进神经网络，而是把经典多视图几何重新组织成可学习系统。

4.3　VGGSfM 在研究脉络中的关键作用

从本文的综述主题来看，VGGSfM 的重要性不只在于性能提升，更在于它提供了一个中间范式：既不同于完全基于手工规则和不可微优化的经典系统，也不同于试图直接一步输出几何结果的黑盒前馈模型。它保留了多视图几何的求解结构，同时让学习方法真正参与全局误差最小化过程。因此，VGGSfM 可以被看作 VGG 团队研究主线中的“枢纽工作”。

这一点体现在两个方面。其一，向前看，VGGSfM 直接吸收了 Light Touch 与 CoTracker 系列在几何先验和点轨迹学习方面的成果，使这些前端表征不再只是局部增强模块，而成为整个结构恢复系统的组成部分。其二，向后看，VGGSfM 也为 VGGT 提供了重要对照基线：如果已经能够把优化层纳入可微框架，那么下一步自然会追问，能否进一步在推理阶段减少甚至移除显式优化，从而实现统一前馈预测[7]。

4.4 与传统 SfM 及同类方法的关系

相较于 COLMAP 等传统系统，VGGSfM 的优势主要在于能够借助学习表征改善鲁棒性，并通过统一训练强化全局一致性[2,4]。相较于只在前端使用深度特征、后端仍完全依赖传统不可微求解器的混合方案，VGGSfM 则体现出更强的系统整合能力。

不过，VGGSfM 仍然保留了优化层，说明这一阶段的重点仍是“让几何优化可学习”，而非完全放弃优化。这一点在研究路径上十分关键：它既保留了传统几何的确定性和解释性，也暴露出后续研究进一步追求效率与统一性的方向，即能否在不依赖复杂测试时优化的前提下，直接输出关键三维属性。

4.5 本阶段的小结

总体而言，可微几何优化阶段意味着学习方法开始从“辅助几何”转向“重构几何系统本身”。如果前一阶段的主要任务是提供更好的对应关系，那么这一阶段的主要任务则是重新定义多视图几何系统内部各模块之间的信息流和误差流。VGGSfM 因而成为整条研究主线中承上启下的一环：它既总结了先前关于几何对应学习的成果，也为下一阶段统一前馈式几何预测提供了结构性基础。

第五章　前馈式统一几何预测与方法趋势

5.1　从可微优化到统一前馈推断

在可微 SfM 之后，VGG 团队研究主线继续向“统一化”与“前馈化”推进。*VGGT: Visual Geometry Grounded Transformer* 提出以单个前馈网络直接预测相机参数、深度图、点图和三维点轨迹等关键几何属性，试图将传统多阶段系统进一步压缩为统一模型[7]。这表明研究问题的表述已经从“如何提升某一几何模块”转向“如何以统一表示组织多个几何任务”。

VGGT 的意义不只在于预测速度更快，更在于它反映出多视图几何重建研究的一个重要趋势：学习模型开始承担传统后端优化原本负责的更大一部分工作。相比于需要测试时迭代求解的系统，前馈式方法在部署、复用和跨任务迁移上具有更高潜力[7]。这也是 VGGT 被视为 VGG 团队研究主线阶段性代表作的重要原因。

从方法论上看，VGGT 代表着一个新的研究假设：在足够强的视觉骨干、足够丰富的训练监督和足够统一的任务设计下，模型能够把原本分散在匹配、相机恢复、三角化与优化中的逻辑，部分吸收到共享表示空间中。这意味着多视图几何重建的核心不再只是“如何设计更复杂的求解器”，而是“如何设计能内化几何规律的统一模型”。因此，VGGT 的价值不仅是速度层面的工程优化，更是问题组织方式的变化。

5.2　VGGT 的统一输出思想

与早期将深度估计、位姿估计、轨迹估计分别处理的做法不同，VGGT 更强调多个几何属性之间的内在一致性。相机参数、点图、深度图和三维轨迹并不是相互孤立的输出，而是共享同一场景几何的不同投影形式。将这些任务放到同一模型中联合预测，本质上是在利用多任务约束强化几何一致性[7]。

这种统一输出思想具有两个直接优势。第一，它降低了传统流水线中接口错配的问题。过去不同模块之间往往因为特征表达、坐标系或误差累积方式不同而难以稳定耦合，而统一模型能够在内部自动协调这些关系。第二，它提高了结果的复用潜力。若同一模型已经预测出相机、点图和轨迹，那么这些中间结果便可以同时服务于重建、跟踪、深度估计乃至后续动态场景建模。

5.3　与相关方法的横向比较

为了更好理解 VGGT 的定位，可以将其与 DUSt3R 等近期方法进行对照。DUSt3R 也强调从图像中直接恢复三维几何，并在一定程度上简化传统结构恢复流程[11]。但与 VGG 团队这一主线相比，VGGT 更强调统一的几何属性输出，以及与前述几何先验、轨迹学习和可微 SfM 研究的连续性。

如果进一步与 MASt3R 比较，可以看到另一种重要差异。MASt3R 更强调把图像匹配问题锚定到三维空间中，从而改善匹配与几何恢复之间的联动[12]；而 VGGT

更进一步，希望把相机、深度、点图和轨迹一起纳入统一模型。这意味着前者更像是对“匹配与三维之间关系”的强化，后者则更像是对“整个几何系统输出接口”的统一。二者都体现出多视图几何正在从复杂流程走向统一表示，但关注点并不完全相同。

此外，*Splatter Image: Ultra-Fast Single-View 3D Reconstruction*、*RealFusion* 和 PC^2 虽然聚焦单图条件下的三维恢复或生成先验，但它们同样体现出 VGG 团队对“前馈式三维表示”的持续探索[15-17]。这说明 VGG 团队并非只在传统多视图任务上推进学习化，也在尝试寻找更统一、更高效的三维表示方式。只是从本文主题出发，这些工作更适合作为研究边界上的支线，用于说明 VGG 团队在几何表示和三维生成之间建立联系的努力，而不宜替代多视图几何主线本身。

表 1: VGG 团队多视图几何学习主线的阶段性对比

阶段	代表工作	主要解决的问题	在主线中的作用
几何先验注入	Light Touch[5]	如何让表征学习显式受多视图几何约束	将几何从后端约束前移到注意力学习阶段
对应关系学习	CoTracker / CoTracker3[6,9]	如何获得稳定、密集、可跨时空延续的点轨迹	为后续全局结构恢复提供高质量观测基础
可微结构恢复	VGGSfM[4]	如何把传统 SfM 管线组织成可训练的统一系统	实现从局部模块增强到系统级学习化的过渡
统一前馈预测	VGGT[7]	如何直接预测多种关键几何属性并减少显式优化	标志研究重心从优化驱动转向统一表示驱动

从上表可以看出，VGG 团队的研究并不是简单地不断推出新模型，而是围绕“观测如何获得、系统如何组织、结果如何统一”这三类问题逐步推进。也正因此，其工作非常适合被写成一条研究主线，而不是彼此孤立的代表论文列表。

5.4 向动态几何与统一表示扩展

这一趋势还继续延伸到动态几何场景。*Dynamic Point Maps: A Versatile Representation for Dynamic 3D Reconstruction* 说明，当场景随时间变化时，统一点图表示仍可作为多任务几何建模的重要中间层[20]。尽管这类工作已部分超出本文“多视图几何重建”的核心范围，但它们揭示了一个清晰方向：未来的学习方法可能不再局限于重建某个静态结果，而是形成可支持深度、相机、点云、轨迹乃至动态场景理解的统一几何表征。

这一扩展方向进一步说明，前馈式统一几何预测并不是研究终点，而更像一个平台性阶段。只要模型内部已经形成相对稳定的几何 token 或统一场景表示，那么从

静态多视图重建扩展到视频、动态场景甚至跨任务三维推理，便成为顺理成章的下一步。这也是为什么动态点图等工作虽然在任务形式上已超出经典 SfM 范畴，但在方法论上仍与 VGG 的多视图几何学习主线保持一致。

5.5 本阶段的综合评价

从 VGG 团队近五年的方法演进来看，前馈式统一几何预测并不是凭空出现的，而是建立在前述几何先验注入、点轨迹学习与可微 SfM 逐步成熟的基础之上。也正因为如此，VGGT 等方法更适合被理解为一条研究主线的阶段性总结，而不是孤立的单篇突破。对本文主题而言，本阶段最值得强调的不是单个模型的性能，而是“多视图几何重建正在从优化驱动转向表示驱动与模型驱动”的方法论变化。

不过，这一阶段也暴露出新的挑战。其一，统一前馈模型虽然减少了显式优化，但训练成本与数据依赖往往更高。其二，模型输出越统一，越需要在训练阶段引入足够丰富且相互一致的监督信号，否则容易在某些属性上取得提升、在另一些属性上出现退化。其三，前馈式预测并不必然意味着完全替代几何优化，在高精度或复杂场景下，模型预测与几何求精之间仍可能形成新的混合范式。因此，从研究发展的角度看，未来很可能不是“优化彻底消失”，而是优化与统一表示之间出现新的分工结构。

从综述写作角度说，本阶段还提示我们不应把“前馈化”简单理解为“更快的工程实现”。真正值得强调的是，它改变了几何问题被组织、监督和复用的方式。过去多视图几何系统的中间变量主要服务于求解器本身，而现在统一模型输出的点图、轨迹和相机参数同时具备任务结果与通用表示的双重属性。这种变化使几何重建方法更容易向动态场景理解、具身感知和三维内容生成等领域外溢，也使 VGG 团队这一主线具有超出单一 benchmark 的方法论意义。

第六章　总结与展望

本文围绕“多视图几何重建中的学习方法”这一主题，以 VGG 团队为例梳理了近五年的代表性研究主线。整体来看，该团队的工作并非简单追求端到端替代，而是沿着一条较为清晰的路径逐步推进：先利用几何先验改善跨视角表征，再通过点轨迹学习提升对应质量，随后将结构恢复系统整体可微化，最后进一步走向统一前馈式几何预测[4-7]。

从研究贡献上看，VGG 团队的工作至少体现出三点特色。第一，坚持以多视图几何问题本身为核心，而非将三维重建视作纯粹的黑盒回归任务。第二，强调系统级整合，将对应、优化与表示逐步组织到统一框架中。第三，关注统一几何表示的潜力，使学习方法能够服务于多个相关任务，而不仅限于单一指标提升。

当然，该研究主线也仍面临若干问题。其一，尽管统一前馈模型提高了效率，但对训练数据规模、模型容量和任务设定的依赖也更强。其二，复杂场景中的动态因素、遮挡与泛化问题仍然没有被彻底解决。其三，如何在保持几何可解释性的同时进一步提升模型统一性与迁移能力，仍是未来的重要研究方向。

结合当前发展趋势，后续研究可能继续沿三个方向推进：一是进一步探索更统一的几何中间表示，用同一模型支持相机恢复、深度估计、点云生成与轨迹推断；二是扩展到动态 4D 场景，使学习化多视图几何从静态场景走向时空一致建模；三是与机器人感知、具身智能和三维内容生成等下游任务形成更紧密结合。对课程综述写作而言，VGG 团队的研究体系提供了一个较理想的分析样本，因为它既能代表该方向的重要技术趋势，也便于清晰展示论文之间的递进关系与方法脉络。

进一步说，VGG 团队这条研究主线的重要价值，在于它展示了一种较为稳健的学术推进方式：不是把传统几何完全推翻，也不是停留在局部模块微调，而是在尊重几何结构的基础上逐层引入学习方法。这样的研究路径使得每一步工作都能够与上一阶段形成明确衔接，也使本文能够较为自然地从“问题定义”“对应学习”“可微优化”一路写到“统一前馈预测”。这也说明，一个高质量综述并不只是总结论文结论，更重要的是还原其背后的问题链条与方法选择逻辑。

如果进一步面向课程报告的“分析性”要求来看，本文最终想强调的结论可以概括为两点。第一，多视图几何重建中的学习方法并没有削弱几何本身的重要性，反而让几何约束以更灵活的形式进入特征学习、监督构造与统一表示之中。第二，VGG 团队之所以适合作为综述案例，不仅因为其成果具有代表性，更因为这些成果之间存在可被清晰复原的问题链条：当成对匹配不稳时，就转向更具几何意识的表征和轨迹；当局部增强不足以解决系统性误差时，就转向可微 SfM；当可微优化仍受测试时代价限制时，又进一步探索统一前馈预测。正是这条链条，使本文能够从“以 VGG 团队为例”进一步上升到“理解整个方向如何演进”。

参考文献

[1] TRIGGS B, MCLAUCHLAN P F, HARTLEY R I, et al. Bundle Adjustment – A Modern Synthesis[J]. Lecture Notes in Computer Science, 2000, 1883: 298-372.

[2] SCHÖNBERGER J L, FRAHM J M. Structure-from-Motion Revisited[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 4104-4113.

[3] WANG J, ZHONG Y, DAI Y, et al. Deep Two-View Structure-From-Motion Revisited[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 8953-8962. https://openaccess.thecvf.com/content/CVPR2021/html/Wang_Deep_Two-View_Structure-From-Motion_Revisited_CVPR_2021_paper.html.

[4] WANG J, KARAEV N, RUPPRECHT C, et al. VGGSfM: Visual Geometry Grounded Deep Structure From Motion[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 21686-21697. https://openaccess.thecvf.com/content/CVPR2024/html/Wang_VGGSfM_Visual_Geometry_Grounded_Deep_Structure_From_Motion_CVPR_2024_paper.html.

[5] BHALGAT Y, HENRIQUES J F, ZISSERMAN A. A Light Touch Approach to Teaching Transformers Multi-View Geometry[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 4958-4969. https://openaccess.thecvf.com/content/CVPR2023/html/Bhalgat_A_Light_Touch_Approach_to_Teaching_Transformers_Multi-View_Geometry_CVPR_2023_paper.html.

[6] KARAEV N, ROCCO I, GRAHAM B, et al. CoTracker: It is Better to Track Together[C/OL]//European Conference on Computer Vision (ECCV). 2024. https://arxiv.org/abs/2307.07635.

[7] WANG J, CHEN M, KARAEV N, et al. VGGT: Visual Geometry Grounded Transformer[J/OL]. arXiv preprint arXiv:2503.11651, 2025. https://arxiv.org/abs/2503.11651.

[8] WU S, RUPPRECHT C, VEDALDI A. Unsupervised Learning of Probably Symmetric Deformable 3D Objects from Images in the Wild[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020. https://arxiv.org/abs/1911.11130.

[9] KARAEV N, MAKAROV Y, WANG J, et al. CoTracker3: Simpler and Better Point Tracking by Pseudo-Labelling Real Videos[C/OL]//Proceedings of the

IEEE/CVF International Conference on Computer Vision (ICCV). 2025: 6013-6022. https://openaccess.thecvf.com/content/ICCV2025/html/Karaev_CoTracker3_Simpler_and_Better_Point_Tracking_by_Pseudo-Labelling_Real_Videos_ICCV_2025_paper.html.

[10] REIZENSTEIN J, SHAPOVALOV R, HENZLER P, et al. Common Objects in 3D: Large-Scale Learning and Evaluation of Real-Life 3D Category Reconstruction[C/OL]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 10901-10911. https://openaccess.thecvf.com/content/ICCV2021/html/Reizenstein_Common_Objects_in_3D_Large-Scale_Learning_and_Evaluation_of_Real-Life_ICCV_2021_paper.html.

[11] WANG S, LEROY V, CABON Y, et al. DUSt3R: Geometric 3D Vision Made Easy[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 20697-20709. https://openaccess.thecvf.com/content/CVPR2024/html/Wang_DUSt3R_Geometric_3D_Vision_Made_Easy_CVPR_2024_paper.html.

[12] LEROY V, CABON Y, REVAUD J. Grounding Image Matching in 3D with MASt3R[J/OL]. arXiv preprint arXiv:2406.09756, 2024. https://arxiv.org/abs/2406.09756.

[13] MILDENHALL B, SRINIVASAN P P, TANCIK M, et al. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis[C/OL]//European Conference on Computer Vision (ECCV). 2020: 405-421. https://arxiv.org/abs/2003.08934.

[14] KERBL B, KOPANAS G, LEIMKÜHLER T, et al. 3D Gaussian Splatting for Real-Time Radiance Field Rendering[J/OL]. ACM Transactions on Graphics, 2023, 42(4). https://arxiv.org/abs/2308.04079.

[15] MELAS-KYRIAZI L, LAINA I, RUPPRECHT C, et al. RealFusion: 360deg Reconstruction of Any Object From a Single Image[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 8446-8455. https://openaccess.thecvf.com/content/CVPR2023/html/Melas-Kyriazi_RealFusion_360deg_Reconstruction_of_Any_Object_From_a_Single_Image_CVPR_2023_paper.html.

[16] MELAS-KYRIAZI L, RUPPRECHT C, VEDALDI A. PC2: Projection-Conditioned Point Cloud Diffusion for Single-Image 3D Reconstruction[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 12923-12932. https://openaccess.thecvf.com/content/CVPR2023/html/Melas-Kyriazi_PC2_Projection-Conditioned_Point_Cloud_Diffusion_for_Single-Image_3D_Reconstruction_CVPR_2023_paper.html.

[17] SZYMANOWICZ S, RUPPRECHT C, VEDALDI A. Splatter Image: Ultra-Fast Single-View 3D Reconstruction[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 10208-10217. https://openaccess.thecvf.com/content/CVPR2024/html/Szymanowicz_Splatter_Image_Ultra-Fast_Single-View_3D_Reconstruction_CVPR_2024_paper.html.

[18] KARAEV N, ROCCO I, GRAHAM B, et al. DynamicStereo: Consistent Dynamic Depth From Stereo Videos[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 13229-13239. https://openaccess.thecvf.com/content/CVPR2023/html/Karaev_DynamicStereo_Consistent_Dynamic_Depth_From_Stereo_Videos_CVPR_2023_paper.html.

[19] SHTEDRITSKI A, RUPPRECHT C, VEDALDI A. SHIC: Shape-Image Correspondences with no Keypoint Supervision[C/OL]//European Conference on Computer Vision (ECCV). 2024. https://www.robots.ox.ac.uk/~vgg/publications/2024/Shtedritski24/.

[20] SUCAR E, LAI Z, INSAFUTDINOV E, et al. Dynamic Point Maps: A Versatile Representation for Dynamic 3D Reconstruction[J/OL]. arXiv preprint arXiv:2503.16318, 2025. https://arxiv.org/abs/2503.16318.